What is Intelligence and AI?

মানুষ হাজার বছর ধরে একটা স্বপ্ন দেখে এসেছে — এমন কিছু তৈরি করা যা তার মতোই চিন্তা করতে পারে, শিখতে পারে, সিদ্ধান্ত নিতে পারে। এই স্বপ্নই আজকের Artificial Intelligence-এর জন্ম দিয়েছে। কিন্তু machine কে intelligent করতে হলে আগে বুঝতে হবে — intelligence আসলে কী?

Intelligence কী?

Intelligence মানে শুধু facts জানা না। Intelligence হলো একটা cyclic process — পরিবেশ থেকে তথ্য নাও, সেটা থেকে শেখো, সিদ্ধান্ত নাও, কাজ করো, আবার নতুন তথ্য নাও। এই loop-টাই intelligent behavior-এর মূল।

একটা শিশু যখন হাঁটতে শেখে, সে প্রতিবার পড়ে যায়, তারপর adjust করে, আবার চেষ্টা করে। একজন ডাক্তার যখন রোগ নির্ণয় করেন, তিনি past experience থেকে pattern match করেন। এই ability গুলোকে চারটি ভাগে ভাগ করা যায়:

- **Learn:** নতুন তথ্য absorb করা
- **Adapt:** নতুন পরিবেশে টিকে থাকা
- **Reason:** জটিল সমস্যা সমাধান করা
- **Remember:** অতীত ব্যবহার করে ভবিষ্যৎ guide করা

মানুষ এই চারটি কাজ স্বাভাবিকভাবেই করতে পারে। প্রশ্ন হলো — machine কি পারবে?

AI-এর জন্ম: Dartmouth, 1956

1955 সালে McCarthy, Minsky, Shannon এবং Rochester মিলে একটা proposal লিখলেন। তাঁদের ধারণা ছিল — intelligence-এর প্রতিটি দিক এত precisely describe করা সম্ভব যে machine সেটা simulate করতে পারবে। এই proposal-এর ভিত্তিতে 1956 সালে Dartmouth College-এ একটি summer workshop হয় এবং সেখানেই প্রথমবার "Artificial Intelligence" শব্দটি officially ব্যবহার হয়।

তার আগে 1950 সালে Alan Turing একটি প্রশ্ন রেখেছিলেন — "Can machines think?" তিনি বলেছিলেন, যদি একটি machine কোনো মানুষের সাথে conversation করে এবং সেই মানুষ বুঝতে না পারে যে সে machine-এর সাথে কথা বলছে, তাহলে সেই machine কে intelligent বলা যায়। এটাই Turing Test।

AI আসলে কী?

সহজ ভাষায়, AI হলো এমন software যা এমন কাজ করতে পারে যেগুলো সাধারণত human intelligence দরকার হয় — যেমন দেখা, শোনা, কথা বলা, সিদ্ধান্ত নেওয়া।

কিন্তু আজকের AI এবং মানুষের intelligence-এর মধ্যে একটা বড় পার্থক্য আছে। এখন দুটো ভাগ আছে:

	ANI (Narrow AI)	AGI (General AI)
সংজ্ঞা	একটি নির্দিষ্ট কাজে expert	যেকোনো কাজে সক্ষম
উদাহরণ	Chess AI, Face Recognition	Human-level thinking
বর্তমান অবস্থা	বিদ্যমান	এখনও hypothetical

আজকের সব AI — ChatGPT, Google Photos, Siri — সবই ANI। এরা প্রত্যেকে একটা নির্দিষ্ট কাজে অসাধারণ, কিন্তু সেই কাজের বাইরে কিছু করতে পারে না। Chess খেলা AI কোনো poem লিখতে পারবে না।

কেন AI এখন এত শক্তিশালী?

AI 1950 সাল থেকেই আছে। তাহলে হঠাৎ এখন এত বড় হলো কেন? তিনটি কারণ একসাথে মিলেছে:
প্রথমত, **Big Data** — internet-এর কারণে এখন machine কে শেখানোর জন্য কোটি কোটি example পাওয়া যায়।
দ্বিতীয়ত, **Powerful GPUs** — এমন hardware তৈরি হয়েছে যা এই বিশাল data দ্রুত process করতে পারে। তৃতীয়ত, **Better Algorithms** — গত দশ বছরে mathematics এবং optimization-এ নতুন discoveries হয়েছে।
এই তিনটি জিনিস একসাথে মিলেই AI revolution সম্ভব হয়েছে।

Recommended Resources

AI-এর journey আরও deeply বুঝতে এই দুটো দেখতে পারো:

> **Fei-Fei Li and Andrew Ng on Human-Centered AI** — Image AI-এর pioneer Fei-Fei Li-এর দৃষ্টিভঙ্গি
> **The Thinking Game** (Google DeepMind documentary) — AI কীভাবে Chess এবং Go জিতলো তার গল্প

Summary

Intelligence হলো learn, adapt, reason এবং remember করার ক্ষমতা। 1956 সালে Dartmouth-এ "Artificial Intelligence" শব্দটির জন্ম হয়, এবং লক্ষ্য ছিল machine-কে এই ক্ষমতা দেওয়া। আজকের AI হলো Narrow AI — নির্দিষ্ট কাজে অত্যন্ত দক্ষ। Big Data, GPU এবং নতুন algorithms মিলে এই field-টিকে এখন যেখানে নিয়ে এসেছে।

What is ML and DL?

আগের page-এ আমরা দেখেছিলাম AI কী এবং কীভাবে এর জন্ম হয়েছিল। কিন্তু AI একটি বড় ছাতার মতো — এর নিচে অনেক কিছু আছে। সেই ছাতার নিচে দুটো সবচেয়ে গুরুত্বপূর্ণ জিনিস হলো Machine Learning এবং Deep Learning। আজকে আমরা বুঝবো এই দুটো আসলে কী, এবং এরা একে অপরের থেকে কীভাবে আলাদা।

Traditional Programming vs Machine Learning

প্রথমে একটু পিছনে যাই। পুরনো দিনে programmer-রা যা করতো তা ছিল এরকম — একটা problem-এর জন্য manually সব rules লিখে দাও। যেমন, cat detect করার জন্য লিখতে হতো:

```
1If (Has Ears) AND (Has Whiskers) AND (Is Furry) THEN → Cat
```

এই approach-এর সমস্যা হলো, real world অনেক complex। যদি cat টা box-এর পেছনে থাকে? যদি whisker ছাড়া কোনো dog থাকে? প্রতিটা exception-এর জন্য নতুন rule লিখতে হবে — এটা কখনো শেষ হবে না।

1959 সালে Arthur Samuel একটা নতুন idea দিলেন। তিনি একটা checkers-playing program বানালেন। তিনি program-কে rules দেননি — দিয়েছিলেন শেখার ক্ষমতা। Program নিজে নিজে হাজার হাজার game খেলে, জিতলে কী হয় হারলে কী হয় সেটা দেখে, নিজেই pattern বুঝে নিলো। একসময় সেই program Samuel-কেই হারিয়ে দিলো।
এটাই Machine Learning-এর জন্ম।

Machine Learning কী?

Machine Learning হলো AI-এর এমন একটি approach যেখানে machine-কে explicitly rules দেওয়া হয় না — বরং data দেওয়া হয়, এবং machine সেই data থেকে নিজেই pattern শেখে।
Traditional Programming এবং ML-এর পার্থক্যটা এভাবে দেখা যায়:

	Traditional Programming	**Machine Learning**
Input	Rules + Data	Data + Answers
Output	Answers	Rules (learned)
কাজ	Programmer rules লেখে	Machine নিজে rules বের করে

ML আজকে কোথায় ব্যবহার হচ্ছে? Gmail-এ spam filter করছে, Netflix recommend করছে, weather predict করছে — সবখানে ML আছে। এই সব জায়গায় কেউ manually rule লেখেনি, machine নিজেই data থেকে শিখেছে।

Deep Learning কী?

ML-এর মধ্যেই একটি বিশেষ approach আছে যেটা মানুষের brain থেকে inspired — সেটা হলো Deep Learning। মানুষের brain-এ কোটি কোটি neuron আছে, এরা interconnected। একটা neuron অন্য neuron থেকে signal নেয়, process করে, পাঠায়। Deep Learning-এ এই structure-টাকেই artificially তৈরি করা হয় — এটাকে বলে Neural Network।
একটা Neural Network-এ তিনটি অংশ থাকে:

```
Input Layer → Hidden Layers → Output Layer
(Raw Data)    (Pattern Find)   (Answer)
```

উদাহরণ হিসেবে একটা cat photo detect করার কথা ভাবো। Input layer-এ ছবির প্রতিটি pixel আসে। Hidden layers গুলো প্রথমে edges detect করে, তারপর সেই edges মিলিয়ে shapes বানায়, তারপর shapes মিলিয়ে features (যেমন ear, whisker) বানায়। শেষে Output layer বলে — "এটা Cat।"
"Deep" মানে হলো এই Hidden Layers অনেক বেশি — layer যত বেশি, network তত "deep"।

তিনটির সম্পর্ক

এই তিনটি concept অনেকে গুলিয়ে ফেলে। আসলে এরা একটার মধ্যে আরেকটা:

```
Artificial Intelligence
```

```
    └── Machine Learning
        └── Deep Learning
```

AI হলো সবচেয়ে বড় concept — machine দিয়ে intelligent কাজ করানো। ML হলো AI করার একটি পদ্ধতি — data থেকে শেখা। Deep Learning হলো ML-এর একটি বিশেষ technique — Neural Network ব্যবহার করে শেখা। সব ML, Deep Learning না। কিন্তু সব Deep Learning, ML-এর অংশ।

কোনটা কখন ব্যবহার হয়?

Situation	কোনটা ব্যবহার হয়
Structured data, simple pattern	Traditional ML
Images, Audio, Text	Deep Learning
খুব কম data	Traditional ML
বিশাল data আছে	Deep Learning

Deep Learning অনেক powerful, কিন্তু এর জন্য দরকার প্রচুর data এবং powerful hardware। Traditional ML কম data-তেও ভালো কাজ করে।

Summary

Traditional programming-এ manually rules লিখতে হতো, Machine Learning-এ machine নিজেই data থেকে rules শেখে। Deep Learning হলো ML-এর একটি বিশেষ approach যেখানে human brain-এর মতো Neural Network ব্যবহার করা হয়। AI > ML > Deep Learning — এই তিনটি একটার মধ্যে আরেকটা nested, আলাদা আলাদা জিনিস না।

Current & Future of AI + Types of ML

আগের দুটো page-এ আমরা বুঝেছি AI কী, ML কী, DL কী। এখন দুটো গুরুত্বপূর্ণ প্রশ্নের উত্তর দেবো — AI দিয়ে আসলে কী কী করা যাচ্ছে এবং ভবিষ্যতে কী হবে? আর ML-এ কত ধরনের approach আছে?

AI এখন কোথায় কোথায় আছে?

AI এখন আর শুধু research lab-এ নেই। প্রতিদিনের জীবনে AI ঢুকে গেছে এমনভাবে যে আমরা টের পাই না।

Healthcare-এ AI এখন cancer-এর early signs detect করতে পারছে, X-ray দেখে রোগ নির্ণয় করছে। একজন অভিজ্ঞ ডাক্তারের চেয়েও কিছু ক্ষেত্রে বেশি accurately।

Science-এ DeepMind-এর AlphaFold protein folding problem solve করেছে — এটা biology-তে 50 বছরের পুরনো একটা সমস্যা ছিল। লক্ষ লক্ষ protein-এর 3D structure predict করে ফেলেছে যা manually করতে decades লাগতো।

Coding-এ AI assistant এখন software লিখছে, bug fix করছে। **Art-**এ AI image এবং text generate করছে। এই field গুলোতে AI এখন human-এর সাথে collaborate করছে।

ভবিষ্যতে AI কোথায় যাবে?

এখানে একটু সতর্কতার সাথে বলা দরকার। AI-এর ভবিষ্যৎ নিয়ে দুটো দিক আছে।

একদিকে possibility অনেক বড়। AGI যদি কোনোদিন তৈরি হয় — এমন AI যে যেকোনো কাজ করতে পারবে — সেটা মানব সভ্যতাকে সম্পূর্ণ বদলে দেবে। Disease cure করবে, climate change solve করবে, নতুন physics আবিষ্কার করবে।

অন্যদিকে challenge-ও আছে। Job displacement, privacy, bias, misuse — এই সমস্যাগুলো real। Fei-Fei Li-এর মতো researchers বলছেন AI কে human-centered রাখতে হবে — technology মানুষের জন্য, মানুষ technology-র জন্য না।

Types of ML: কত ধরনের শেখার পদ্ধতি আছে?

Machine Learning-এ একটাই পদ্ধতিতে শেখা হয় না। মূলত তিনটি approach আছে, প্রতিটির আলাদা context আছে।

Supervised Learning

এখানে machine শেখে একজন teacher-এর মতো — data দেওয়া হয় এবং সাথে correct answer-ও দেওয়া হয়। Machine এই input-output pair থেকে relationship শিখে নেয়।

ধরো তুমি একটা শিশুকে শেখাচ্ছো। প্রতিটা ছবি দেখিয়ে বলছো "এটা Apple, এটা Orange।" শিশু pattern শিখে নিচ্ছে। Supervised Learning ঠিক এভাবেই কাজ করে।

Supervised Learning-এর দুটো প্রধান কাজ আছে:

Regression — যখন output একটা continuous number। যেমন বাড়ির size, location, age দেখে price predict করা। Answer হবে একটা নির্দিষ্ট সংখ্যা, যেমন $450,200।

Classification — যখন output একটা category। যেমন email টা Spam নাকি Not Spam। Answer হবে একটা label।

	Regression	Classification
প্রশ্ন	"কত?"	"কোনটা?"
Output	Continuous number	Category/Label
উদাহরণ	Salary prediction	Spam detection

Unsupervised Learning

এখানে machine শেখে একজন explorer-এর মতো — শুধু raw data দেওয়া হয়, কোনো correct answer দেওয়া হয় না। Machine নিজেই data-র মধ্যে hidden pattern খোঁজে।

একটা শিশুকে এলোমেলো LEGO দিয়ে বললে "নিজের মতো সাজাও।" সে নিজেই রঙ, আকার দেখে group করবে। Unsupervised Learning এভাবেই কাজ করে।

সবচেয়ে common কাজ হলো **Clustering** — similar জিনিসগুলোকে একসাথে group করা। যেমন একটা shopping mall তার customers-দের label না জেনেও তাদের spending pattern দেখে তিনটি group বের করতে পারে: young tech spenders, weekly grocery shoppers, occasional luxury buyers। এই labels কেউ দেয়নি, machine নিজেই বের করেছে।

Reinforcement Learning

এটা তৃতীয় একটি approach যেখানে machine শেখে trial and error করে — ঠিক কাজ করলে reward পায়, ভুল করলে penalty পায়। এভাবে সে ধীরে ধীরে সেই behavior শেখে যেটায় reward বেশি।

Chess বা Go খেলা AI এভাবেই শেখে। লক্ষ লক্ষ game খেলে, জিতলে positive signal, হারলে negative signal — এভাবেই সে world champion-দের হারাতে পেরেছে।

তিনটির পার্থক্য এক নজরে

	Supervised	Unsupervised	Reinforcement
Data	Labeled	Unlabeled	Environment
Teacher	আছে	নেই	Reward/Penalty
কাজ	Predict	Discover	Optimize
উদাহরণ	Spam filter	Customer grouping	Game playing AI

Summary

AI এখন healthcare, science, coding, art সহ প্রায় সব field-এ ঢুকে গেছে। ভবিষ্যতে possibility অনেক বড় কিন্তু human-centered approach দরকার। ML-এ তিনটি প্রধান approach আছে — Supervised Learning-এ labeled data দিয়ে শেখানো হয়, Unsupervised Learning-এ machine নিজেই pattern খোঁজে, আর Reinforcement Learning-এ reward এবং penalty দিয়ে শেখানো হয়।

ML Pipeline-overview

আমরা এতক্ষণ জেনেছি ML কী, কত ধরনের ML আছে। কিন্তু বাস্তবে একটা ML project কীভাবে শুরু থেকে শেষ পর্যন্ত তৈরি হয়? একটা idea থেকে কীভাবে একটা working AI system হয়? এই পুরো journey-টাকে বলা হয় ML Pipeline। এটা একটা blueprint — প্রতিটা real ML project এই steps follow করে।

Pipeline মানে কী?

Pipeline মানে একটা sequential process যেখানে প্রতিটা step-এর output পরের step-এর input হয়। ML Pipeline মানে হলো data থেকে শুরু করে deployed model পর্যন্ত পৌঁছানোর structured path। এই path skip করলে model কাজ করবে না বা production-এ গিয়ে fail করবে।

Step 1: Problem Framing

সবকিছুর আগে একটাই প্রশ্ন — আমরা আসলে কী predict করতে চাই?
এই step-এ তিনটি জিনিস ঠিক করতে হয়। প্রথমত, problem টা Regression নাকি Classification — মানে answer টা একটা number নাকি একটা category। দ্বিতীয়ত, success কীভাবে measure করবো — যেমন 90% accuracy। তৃতীয়ত, আমাদের Target Variable কী — যেটা predict করতে চাই।
এই step টা সবচেয়ে গুরুত্বপূর্ণ। Problem ভুলভাবে define করলে বাকি সব কাজ বৃথা।

Step 2: Data Collection

Problem define হলে দরকার data। তিন ধরনের data source থাকতে পারে:

```
Structured Data    →   SQL database, Excel, CSV
Unstructured Data  →   Images, Text, Audio
Real-time Streams  →   Sensor data, API feeds
```

Real world-এ data কখনো clean থাকে না। Missing values থাকে, duplicate থাকে, format আলাদা থাকে। এজন্যই পরের step দরকার।

Step 3: Data Preprocessing

Raw data কে usable করার process। তিনটি প্রধান কাজ:

Missing Values — কোনো row-এ data নেই, সেটা drop করবো নাকি average দিয়ে fill করবো সেটা decide করতে হয়।

Outliers — অস্বাভাবিক values যেগুলো result skew করে দেয়। যেমন salary dataset-এ একজনের salary 10 কোটি হলে সেটা বাকিদের average নষ্ট করে দেবে।

Encoding — Machine numbers বোঝে, words বোঝে না। তাই "Green" → 1, "Red" → 2 এভাবে convert করতে হয়।

Step 4: Feature Engineering

এটা ML Pipeline-এর সবচেয়ে creative step। Raw data থেকে নতুন meaningful signals তৈরি করা হয়।
তিনটি কাজ এখানে হয়:

Extraction — Raw data থেকে নতুন feature বানানো। যেমন একটা timestamp থেকে "Day of the Week" বা "Is it a Holiday?" বের করা।

Scaling — Age (0-100) এবং Income (0-10,00,000) একই model-এ দিলে Income সব attention নিয়ে নেবে। Scaling করলে দুটো equal weight পাবে।

Selection — সব feature দরকার না। Customer-এর favorite color কি তার churn predict করতে সাহায্য করবে? এই noise গুলো বাদ দিতে হয়।

Step 5: Train-Test Split

Model কে শেখানোর আগে data কে দুই ভাগ করতে হয়:

```
পুরো Dataset
├── Training Set (80%)  →  Model এখান থেকে শেখে
└── Testing Set  (20%)  →  Model এখানে test হয়
```

Rule হলো — test data model কখনো দেখবে না training-এর সময়। এটা exam-এর মতো। আগে থেকে answer sheet দেখিয়ে দিলে model আসলে কতটা শিখেছে সেটা বোঝা যাবে না।

Step 6: Model Training

এখন actual শেখার কাজ শুরু হয়। Algorithm data-র মধ্য দিয়ে বারবার যায়, প্রতিবার তার internal weights adjust করে, যতক্ষণ না error minimized হয়।
এটা অনেকটা একটা scale calibrate করার মতো। একটু এদিক, একটু ওদিক adjust করতে করতে একসময় perfect balance খুঁজে পাওয়া যায়।

Step 7: Evaluation

Model train হলে test set-এ দেখতে হয় সে কেমন perform করলো। কিন্তু শুধু accuracy দেখলেই হয় না।

একটা fraud detection model-এ যদি সে সব transaction-কে "Not Fraud" বলে দেয়, accuracy 99% হতে পারে — কিন্তু সে আসলে কোনো কাজই করছে না। এজন্য problem অনুযায়ী metric বেছে নিতে হয়:

```
Bank Fraud Detection  →  Recall বেশি গুরুত্বপূর্ণ
                         (একটা fraud-ও miss করা যাবে না)

Social Media Filter   →  Precision বেশি গুরুত্বপূর্ণ
                         (ভালো content block করা যাবে না)
```

Step 8: Hyperparameter Tuning

Model-এর কিছু settings আছে যেগুলো training-এর আগে manually set করতে হয় — এগুলোকে বলে Hyperparameters। যেমন একটা decision tree কতটা deep হবে সেটা।

Grid Search হলো সব possible combination try করে best setting খুঁজে বের করা। এটা time-consuming কিন্তু model-এর performance অনেক বাড়িয়ে দেয়।

Step 9: Deployment ও Monitoring

সব ঠিক হলে model production-এ যায় — cloud-এ API হিসেবে deploy হয়। Real user তখন data পাঠায়, milliseconds-এ answer পায়।

কিন্তু এখানেই শেষ না। **Model Drift** একটা বড় সমস্যা — সময়ের সাথে দুনিয়া বদলায়, কিন্তু model-এর শেখা পুরনো থাকে। 2020-এর data দিয়ে train করা model 2025-এ outdated হয়ে যাবে। তাই continuous monitoring দরকার।

Pipeline টা Circular

```
Problem → Data → Preprocess → Features → Train → Evaluate → Deploy → Monitor
                                                                      ↓
                                                                (নতুন data)
                                                                      ↓
                                                                আবার শুরু
```

ML কোনো one-time project না। এটা একটা living system যেটা নতুন data পেলে আবার শেখে, আবার improve হয়।

Step গুলো এক নজরে

Step	নাম	কাজ
1	Problem Framing	কী predict করবো ঠিক করা
2	Data Collection	Structured, Unstructured, Realtime data জোগাড়
3	Data Preprocessing	Missing values, Outliers, Encoding ঠিক করা
4	Feature Engineering	নতুন meaningful signals তৈরি করা
5	Train-Test Split	80% train, 20% test ভাগ করা
6	Model Training	Algorithm দিয়ে pattern শেখানো
7	Evaluation	Accuracy, Recall, Precision দিয়ে measure করা
8	Hyperparameter Tuning	Best settings খুঁজে বের করা
9	Deployment & Monitoring	Production-এ পাঠানো এবং নজর রাখা

Summary

ML Pipeline হলো একটা end-to-end blueprint — Problem define করা থেকে শুরু করে production-এ deploy করা পর্যন্ত। প্রতিটা step একটার সাথে আরেকটা connected। Data ভালো না হলে model ভালো হবে না, evaluation সঠিক না হলে deploy করা বিপজ্জনক। আর deploy করার পরেও monitoring চালিয়ে যেতে হয় কারণ ML একটা continuous process।